Data Mining

2. Text mining

Christophe Lalanne

Fall 2017

Analyse de données textuelles

Analyse d’email

Détection de spam

Analyse de données textuelles

Text mining (with R, Robinson and Silge 2017)

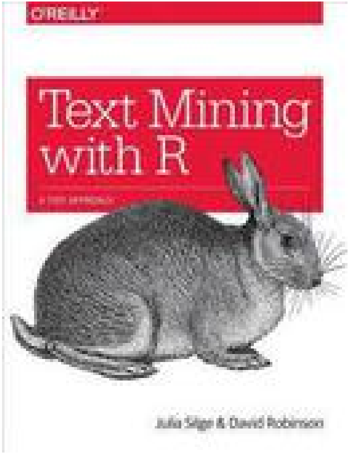

Figure 1: https://www.tidytextmining.com (Github)

Flux de données Twitter

140 (x2 depuis Nov. 2017) caractères + hash tags

Les données Twitter (plus généralement les médias sociaux) peuvent être utilisées dans un cadre de recherche exploratoire ou dans un contexte médical (De Choudhury et al. 2013, McManus et al. (2015)). Ces données servent généralement de point d'entrée à un modèle prédictif, mais il est également possible de prendre en compte la dimension temporelle. L'analyse de sentiments ({positif, négatif, neutre}, {joy, sadness, fear, anger, ...}) est également largement répandue.

Packages R : `{twitteR}` avec OAuth, `{streamR}`, `{syuzhet}`, `{sentiment}` (depr.), `{sentimentr}`, `{qdap}`, `{quanteda}`, ...
Tutoriels : https://sites.google.com/site/miningtwitter/references.

Illustration

```
library(twitteR)  ## cf. setup_twitter_oauth()
library(stringr)
tw = userTimeline("chlalanne", n = 1000)
find.tag = function(x)
  unlist(str_extract_all(x$getText(), "#[A-Za-z0-9]*"))
tags = lapply(tw, function(x) try(find.tag(x),
              silent = TRUE))
sort(table(unlist(tags)), decr = TRUE)
```

```r
library(snippets)
wcl = table(unlist(tags))
names(wcl) = str_replace_all(names(wcl), "#", "")
cloud(wcl[wcl > 5])
```

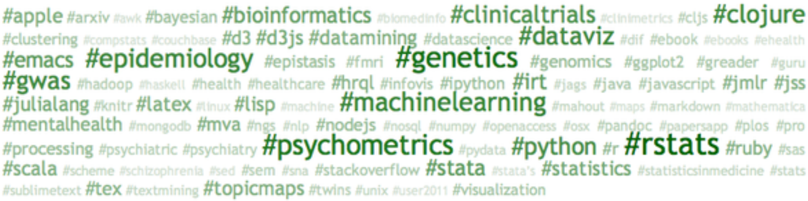

Note : Le package `snippets` n'est plus disponible sur CRAN mais peut être installé depuis RForge.

Application

Text Mining the Complete Works of William Shakespeare

Analyse d’email

Analyse d'emails

Enron data set (`enron.db`, SQLite)

```
% sqlite enron.db
sqlite> .tables
Employee          EmployeeWithVars  MessageBase RecipientBase
EmployeeBase      Message           Recipient
sqlite> .schema Message
CREATE VIEW Message AS
SELECT
    mid,
    filename,
    datetime(unix_time, 'unixepoch') AS time,
    unix_time,
    subject,
    from_eid
FROM
    MessageBase;
```

```
sqlite> select * from Message limit 5;
1|taylor-m/sent/11|1998-11-13 04:07:00|910930020| …
2|taylor-m/sent/17|1998-11-19 07:19:00|911459940| …
3|taylor-m/sent/18|1998-11-19 08:24:00|911463840| …
```

Importation de la base de données sous R :

```r
library(dplyr)
con = src_sqlite("enron.db")
d = tbl(con, "Message")
head(d, 3)
```

Tutoriel dplyr/SQL : MySQL and R Webinar.

“Lazy” operation

```
y = mutate(d, year = substr(time, 1, 4))
## collect(y)
head(y, 3)
```

Dans la mesure du possible, `dplyr` “traduit” le code R en code SQL.

```
> show_query(select(y, year))
<SQL>
SELECT `year` AS `year`
FROM (SELECT `mid`, `filename`, `time`, `unix_time`,
  `subject`, `from_eid`, substr(`time`, 1, 4) AS `year`
FROM `Message`)
```

```
> summary(as.numeric(collect(select(y, year))[[1]]))
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
   1998    2001    2001    2001    2001    2002
```

Détection de spam

Un problème supervisé

`ElemStatLearn::spam`

- 4601 mail classés en spam ou non
- fréquence relative de 57 mots-clés (pour chaque classe)
- `spam_names.txt`

```
if (george < 0.6) and (you > 1.5) then spam
else email
```

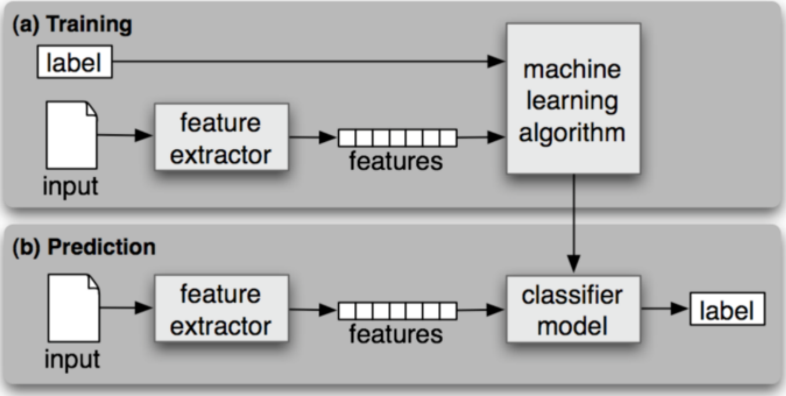

Figure 2: Source : NLTK documentation

Classifier naïf bayésien

$$\underset{c}{\text{argmax}}\; p(C = c) \prod_{i=1}^{n} p(F_i = f_i \mid C = c)$$

```
data(spam, package = "ElemStatLearn")
library(klaR)

# set up a training sample
train.ind = sample(1:nrow(spam), ceiling(nrow(spam)*2/3))

# apply NB classifier
nb.res = NaiveBayes(spam ~ ., data = spam[train.ind,])
```

Rappels sur la validation croisée

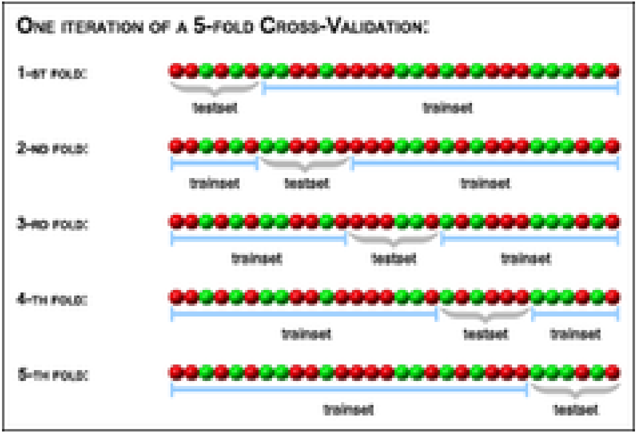

Figure 3: Validation croisée de type “k-fold” (Source : https://genome.tugraz.at/proclassify/help/pages/XV.html)

Résultats

```
> # predict on holdout units
> nb.pred = predict(nb.res, spam[-train.ind,])

> # raw accuracy
> confusion.mat = table(nb.pred$class,
                      spam[-train.ind,"spam"])
> confusion.mat

        email spam
  email   519   34
  spam    420  560
> sum(diag(confusion.mat))/sum(confusion.mat)
[1] 0.7038487
```

References

De Choudhury, M., M. Gamon, S. Counts, and E. Horvitz. 2013. "Predicting Depression via Social Media." *ICIYSM* 2.

McManus, K., E. K. Mallory, R. L. Goldfeder, W. A. Haynes, and J. D. Tatum. 2015. "Mining Twitter Data to Improve Detection of Schizophrenia." *AMIA Jt Summits Transl Sci Proc* 2015:122–26.

Robinson, David, and Julia Silge. 2017. *Text Mining with R, a Tidy Approach*. O'Reilly Media Inc.